


软件测试复习



模糊测试设计

VOS（语音操作系统）旨在为用户提供车内环境下的语音交互服务。该系统采用了唤醒、语音识别、语义理解等技术实现语音控制，可通过语音来操作座舱的车设车控、地图导航、音乐及多媒体应用、系统设置、空调等。除了针对车身、车载的控制外，语音还支持天气查询、日程管理以及闲聊对话。用户只要说唤醒词，即可使用。语音指令可以一步直达功能，既能解放手指，又无需视线偏移注视车机中控区域，从而保障行车安全。而模糊测试是一种通过向目标系统提供非预期的输入并监视异常结果来发现软件异常的方法，其包含数据生成、测试运行、结果反馈等环节。**请设计一种基于模糊测试的方法来检测语音识别模型的鲁棒性。**其中，网络为黑盒，内部结构不可见；该网络可以运行于不同的硬件环境。（提示：可以考虑到行驶环境的差异和环境的影响。注意：至少包含1种子选择策略、3种子变异策略和2种测试评估准则）



模糊测试设计

- 1. 测试目标与假设

- 被测对象（**SUT**）：车载语音识别模型（黑盒），接口形如：输入音频 $a \rightarrow$ 输出转写文本 t （可选输出：置信度、时间戳、N-best）。

部署环境：硬件集合 $H = \{h_1, \dots, h_k\}$ （不同 SoC/CPU/GPU/NPU、不同推理后端/精度）。

鲁棒性关注点：

- 在真实行驶环境噪声、混响、回声、通道效应下，转写应稳定（不产生灾难性错误）。
- 在不同硬件环境上，同一输入应保持一致或差异可控（避免“同一句话不同硬件识别不同”）。



模糊测试设计

- 2. 种子语料与标注
- 种子集合 C : 录制或合成的车载语音指令音频，覆盖 VOS 典型域:
- 唤醒词片段 + 指令 (“你好xx, 打开空调/导航到.../播放音乐...”)
- 车控 (空调、车窗、座椅、灯光)
- 导航 POI/地址 (包含数字、地名、多音字)
- 媒体 (歌名、艺人名)
- 查询 (天气、日程)
- 闲聊 (开放域，作为 “非指令干扰”)
- 基线参考: 每条种子音频有参考文本 t^* (可人工标注或从干净录音获得)，便于计算 WER/CER。



模糊测试设计

- 3. 模糊测试闭环流程（生成—运行—反馈）
- 初始化：对每个种子 $a \in C$ ，在所有硬件 $h \in H$ 上运行，得到基线转写 $t_h(a)$ 。
- 循环迭代：
 - 按“种子选择策略”选出一个或一批种子；
 - 用“变异策略”生成非预期输入 a' （模拟不同车况/噪声/通道）；
 - 在所有硬件上执行：得到 $t_h(a')$ ；
 - 按“评估准则”计算鲁棒性缺陷分数并反馈：高价值样本入库、触发告警、更新优先级。
- 输出报告：列出触发样本、变异类型、触发硬件、错误类型（唤醒误触发/漏识别/指令关键词丢失等）。



模糊测试设计

- 4. 种子选择策略（至少 1 种）
- **S1：临界/高风险指令优先（Uncertainty + Safety-Critical Prioritization）**
- 为每条种子计算优先级：
- **指令风险权重：**与行车安全/驾驶干扰相关的指令更高（如导航、电话、空调除雾等）。
- **语言学脆弱性：**含数字、专有名词、地名、多音字、同音词的种子更高。
- **历史不稳定性：**若该种子在多硬件间基线转写已出现差异或在少量噪声下容易错，则优先。
- 可形式化为：
- $Score_{seed}(a) = \alpha \cdot Risk(a) + \beta \cdot FragileLex(a) + \gamma \cdot D_{crossHW}(a) + \delta \cdot ErrHistory(a)$
- **解释：**ASR 鲁棒性缺陷往往集中在“关键词/数字/实体”与“安全关键指令”上；同时跨硬件不一致的样本是工程高风险点，应优先深挖。



模糊测试设计

- 5. 种子变异策略（至少 3 种；这里给 4 种，均贴合行驶环境）
- M1：行驶噪声叠加（Road/Engine/Wind Noise Mixing）
- 将真实或公开噪声库中的：发动机声、胎噪、风噪、雨刷、转向灯、路面颠簸、隧道噪声等，以不同 SNR 混入语音：
- $\text{SNR} \in \{20, 10, 5, 0\} \text{ dB}$ （从轻到重）
- 目的：模拟不同车速/路况（城市低速、快速路、高速、隧道）导致的噪声差异。
- M2：车内混响与通道效应（RIR/Filter）
- 施加车厢混响（RIR）或 IIR/FIR 滤波模拟：
- 不同座位位置（驾驶位/后排）
- 车窗开合
- 内饰材料差异
- 目的：模拟车内声学空间变化对识别的影响。



模糊测试设计

- M3: 回声与多源干扰 (Echo + Music/TTS Overlap)
 - 叠加:
 - 正在播放的音乐/电台
 - 导航播报 TTS
 - 副驾/后排说话 (babble)
 - 控制重叠比例 (overlap ratio) 与相对响度。
 - 目的: 模拟真实场景中“系统播报时用户插话”“车内多人交谈”等干扰。
- M4: 语速/音高/口音扰动 (Prosody & Accent Perturbation)
 - 对音频做轻量变换:
 - 语速 $\pm 10\% \sim 20\%$
 - 音高 $\pm 1 \sim 2$ 半音
 - 发音拉长/吞音 (可用拼接或时域拉伸近似)
 - 目的: 覆盖不同驾驶状态 (紧张/急促)、不同说话人差异。
- M5: 片段裁剪与唤醒-指令边界扰动 (Truncation/Delay/Jitter)



模糊测试设计

- 6. 测试评估准则（至少 2 种）
- 面向 VOS 指令，文本层 WER 可能不够“功能相关”。因此引入意图级评估：
- 定义关键词/槽位集合（示例）：
- 意图：{打开空调、调高温度、导航到X、播放Y...}
- 槽位：{温度数值、地点实体、歌名/歌手、开/关状态}
- 从转写 $t_h(a')$ 中抽取槽位（可用规则/轻量 NLU 或正则），计算保持率：
- $Preserve = (\# \text{正确保留的关键槽位}) / (\# \text{应有槽位})$
- 判定：若槽位保持率 $< \kappa$ （如 0.8）或关键槽位丢失（如温度/地点/否定词“不/别”）即判为缺陷候选。
- 解释：在车控场景，用户最关心“系统是否执行了正确动作”，关键槽位丢失比一般错字更危险。

- **E2：跨硬件一致性差异（Cross-HW Transcription Divergence）**
- 对同一变异输入 a' ，比较不同硬件的输出文本差异：
- 计算任意两硬件转写的编辑距离（或归一化距离）：
- 判定：若 $D_{crossHW}(a') > \eta$ （如 0.15~0.25），则判为“跨部署不一致风险”。
- 解释：车载系统常有多硬件版本/多推理后端，跨平台不一致会导致同一句话在不同车型上行为不同，是典型工程痛点。



模糊测试设计

- M3: 回声与多源干扰 (Echo + Music/TTS Overlap)
 - 叠加:
 - 正在播放的音乐/电台
 - 导航播报 TTS
 - 副驾/后排说话 (babble)
 - 控制重叠比例 (overlap ratio) 与相对响度。
 - 目的: 模拟真实场景中“系统播报时用户插话”“车内多人交谈”等干扰。
- M4: 语速/音高/口音扰动 (Prosody & Accent Perturbation)
 - 对音频做轻量变换:
 - 语速 $\pm 10\% \sim 20\%$
 - 音高 $\pm 1 \sim 2$ 半音
 - 发音拉长/吞音 (可用拼接或时域拉伸近似)
 - 目的: 覆盖不同驾驶状态 (紧张/急促)、不同说话人差异。
- M5: 片段裁剪与唤醒-指令边界扰动 (Truncation/Delay/Jitter)



模糊测试设计

- 7. 反馈与语料池更新（让模糊测试“越测越准”）
- 定义“有趣度”用于保留样本：
- $Interest(a') = \lambda_1 \cdot \max_h \Delta WER_h + \lambda_2 \cdot D_{crossHW}(a') + \lambda_3 \cdot (1 - Preserve)$
- 满足任一条件即入库：
- $\max_h \Delta WER_h$ 创新高；
- $D_{crossHW}$ 创新高；
- 关键槽位丢失；
- 触发异常（例如空转写、乱码、超时、崩溃、返回空 N-best）。



GOOD LUCK!

